

Segmentación 3D de Tumores Hepáticos utilizando nnU-Net y HeatMaps de incertidumbre para explicabilidad (XAI)

Diego Álvarez Castillo, Tecnólogo Médico, mención Morfofisiopatología y Citodiagnóstico
Magister en Ciencias de la Ingeniería, Mención Ingeniería Biomédica

Julio 2026, Procesamiento de Imágenes Médicas

Resumen

Este trabajo propone la utilización de un modelo de segmentación tridimensional de tumores hepáticos mediante el uso de la arquitectura de nnU-Net en un dataset de 123 tomografías computarizadas para implementar un modelo de aprendizaje profundo autoconfigurable. La metodología se enfoca en un entrenamiento estándar y preprocesamiento, con adición de robustez mediante validación cruzada. El desempeño del modelo se evalúa a través de métricas de volumen, superficie y sensibilidad, complementando los resultados con una capa de Inteligencia Artificial Explicable (XAI) basada en mapas de calor de incertidumbre. Con esto, se busca no solo obtener una segmentación precisa de los tumores, sino también, proporcionar una herramienta interpretable visiblemente, que apoye la toma de decisiones clínicas y quirúrgicas.

Palabras clave: Segmentación 3D, Hígado, Tumor, Tomografía, Explicabilidad (XAI).

1. Problema de investigación

La segmentación y delimitación está consolidada como un estándar de oro para la planificación de intervenciones quirúrgicas y estudio oncológico de lesiones visibles imagenológicamente, sin embargo, también se presenta como un desafío técnico, tanto para radiólogos como para algoritmos, esto debido a varios factores a tener en consideración, como la heterogeneidad de una lesión, bordes difusos, ruido de fondo, entre otros.¹ En este marco donde la segmentación se posiciona como una herramienta ampliamente utilizada para resecciones y terapias oncológicas, las neoplasias hepáticas son un punto clave a abordar, debido a que es un sitio frecuente de metástasis a distancia, dada su alta irrigación y tamaño, además, dada su función metabólica-detox, que muchas veces se ve alterada y que puede incluso desembocar en el desarrollo de un tumor. El hígado y sus crecimientos malignos ocupan el 3er lugar en mortalidad,² por lo que tumores, tanto primarios como secundarios, cobran una importancia real, dado que gran parte de su alta mortalidad se atribuye a un diagnóstico tardío o mala etapificación del daño del órgano, condición que propicia la aparición del Hepatocarcinoma.³⁻⁶

Sobre el ámbito del Deep-Learning, han surgido arquitecturas basadas en mecanismos de atención global (Transformers) para capturar dependencias espaciales de largo de todo el rango,⁷ sin embargo, su implementación en volúmenes 3D suele verse limitada por su complejidad y coste computacional alto en términos de requerimientos de memoria.⁸ Por otro lado, las redes neuronales convolucionales (CNN) clásicas a menudo requieren un ajuste manual exhaustivo de hiperparámetros y pre-procesamiento en cada dataset,⁹ lo que puede dificultar la reproducibilidad de los modelos.¹⁰

2. Objetivos

- Emplear la arquitectura nnU-Net para la segmentación tridimensional de tumores hepáticos en un Dataset de Imágenes NIfTI.
- Evaluar el desempeño del modelo mediante métricas de rendimiento: Relative Volume Difference, Normalized Surface Dice y Sensibilidad.
- Evidenciar mediante representación visual, la explicabilidad de la segmentación utilizando Mapas de Calor con puntaje de Incertidumbre.

3. Solución propuesta

Esta investigación propone el uso de la arquitectura nnU-Net para abordar la segmentación tridimensional del hígado. Este modelo adquiere relevancia debido a su capacidad de automatizar la configuración en base a las propiedades estadísticas del dataset (fingerprinting), permitiendo optimizar el rendimiento sin la carga computacional de los modelos de atención completa.¹¹ Asimismo, se busca integrar métodos de explicabilidad (XAI) y análisis de incertidumbre para mitigar el efecto de la caja negra, aportando en la visibilidad y adopción en el entorno clínico, garantizando que los resultados sean interpretables y seguros para el apoyo en la toma de decisiones médicas.¹²

4. Descripción del Dataset

La base de datos “3D Liver Segmentation” fue extraída del repositorio de Kaggle, el cual contiene 2 directorios de 123




Figura 1: Plan de implementación y flujo de trabajo propuesto.

archivos .nii en cada una, en la primera carpeta se encuentran las tomografías computarizadas, y los respectivos Labels de segmentación manual como *Ground Truth* se hallan en la segunda carpeta.

5. Plan de implementación

El plan de implementación se detalla con un diagrama en la Figura 1, la cual indica que el estudio inicia con la estandarización de nomenclatura, que en conjunto con el resampling dimensional, definición de parches volumétricos y división en 5-folds generan el dataset que será utilizado para entrenar la nnU-Net, posterior al pre-procesamiento/pre-entrenamiento, se inicia la configuración de la función de coste definida y *Data-Augmentation*. El proceso para minimizar la *Loss* se realizará mediante Gradiente Estocástico con un sistema para evitar *Overfitting* en base a “puntos de guardado” que implementa una estrategia de validación continua, almacenando de forma independiente los pesos del modelo correspondientes al mayor desempeño histórico de validación, posterior a esto se reconstruye el volumen tridimensional de la imagen para dar paso a la evaluación del rendimiento en comparación con los Labels proporcionados por el DataSet, finalmente se aplica la explicabilidad con mapas de calor e incertidumbre indicada, para clarificar la salida del modelo y visualizar la segmentación.

6. Funcionamiento de la nnU-Net

Primeramente, se debe recalcar que la arquitectura nnU-Net no difiere mucho de la U-Net tradicional, sino que, son

las características agregadas de *Fingerprinting* y *Automatización de Configuración* lo que la vuelven una Red Neuronal altamente eficaz en sus tareas. Una vez mencionado esto, la arquitectura U-Net mostrada en la Figura 2, se basa en 2 partes, siendo la primera de esta la ***Contracting Path*** que consta de convoluciones consecutivas y activación ReLU [ReLU (Unidad Lineal Rectificada) es una función de activación ampliamente utilizada en DeepLearning. Funciona induciendo NO linealidad, de manera en que, si el valor de entrada es negativo, lo convierte en 0, pero si el valor es positivo, este queda igual, determinando la activación o apagado de las neuronas], que inician con 64 kernels de espaciado = 2 para la reducción de dimensionalidad, que se duplican a medida avanza el proceso, culminando en 1024 kernels, para luego realizar el denominado *Upsampling* del ***Expanding Path*** que funciona mediante la disminución a la mitad de los kernels y concatenación del mapa de características (de la parte contractiva) copiado y ajustado a la resolución correspondiente, hasta llegar al output segmentado.

El proceso de aprendizaje de la arquitectura nnU-Net, se fundamenta en la minimización iterativa de una función de coste (o pérdida) mediante el algoritmo de Gradiente Descendente Estocástico (SGD). Dado el desbalance de las imágenes médicas en relación tumor-tejido, el modelo emplea una función de pérdida compuesta que combina la Entropía Cruzada (L_{CE}) y la Pérdida de Dice (L_{Dice}).

La función de coste total se define como:

$$L_{total} = L_{CE} + L_{Dice}$$




Figura 2: Arquitectura estándar de una U-Net (simplificado), basado en Artículo original de Isensee et al. (2021)

La **Entropía Cruzada** evalúa la clasificación a nivel de vóxel individual, cuantificando la diferencia entre la distribución de probabilidad predicha y la etiqueta real. Su formulación matemática para un problema multi-clase es:

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(p_{i,c})$$

donde N es el número total de vóxeles, C es el número de clases, $y_{i,c}$ es un indicador binario (1 si la clase c es la correcta para el vóxel i , 0 en caso contrario), y $p_{i,c}$ es la probabilidad predicha por la red a través de la capa Softmax.

Por otro lado, la **Pérdida de Dice** aborda el rendimiento espacial, optimizando directamente el solapamiento volumétrico. Para que esta métrica sea integrable con el optimizador SGD, se requiere leves modificaciones. Por lo tanto, se emplea una aproximación continua conocida como *Soft Dice Loss*:

$$L_{Dice} = 1 - \frac{2 \sum_{i=1}^N y_i p_i + \epsilon}{\sum_{i=1}^N y_i + \sum_{i=1}^N p_i + \epsilon}$$

En esta ecuación, el uso de las probabilidades continuas p_i (en lugar de clasificaciones binarias estrictas) garantiza que la función sea derivable. El término ϵ se añade para prevenir la división por cero.

El objetivo del entrenamiento es encontrar el conjunto de pesos θ que minimice L_{total} . Durante la fase de *backpropa-*

gation, se calcula el gradiente estocástico de la función de coste con respecto a los pesos de la red ($\nabla_{\theta} L_{total}$).

Dado que el *Soft Dice* es diferenciable, el optimizador SGD puede utilizar este gradiente para actualizar los parámetros de la red en la dirección opuesta al error:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L_{total}(\theta_t)$$

donde η representa la tasa de aprendizaje (*learning rate*). Esta formulación matemática asegura que cada iteración del optimizador no solo minimice la incertidumbre de clasificación a nivel de vóxel (guiado por L_{CE}), sino que simultáneamente penalice las discrepancias morfológicas globales, forzando a la red neuronal a delinear los márgenes del hígado y del tejido tumoral con precisión anatómica.

7. Fase experimental

La fase de experimentación se inicia con la conversión de los archivos al formato NIfTI para comenzar el preprocesamiento, donde se incluye primeramente la normalización de nomenclatura.

Es de suma relevancia mencionar que el entrenamiento se planeaba realizar con la configuración estándar de 1000 épocas y 5 pliegues (configuración ideal por defecto), sin embargo, debido a las limitaciones de hardware (principalmente por memoria VRAM de GPU) se terminó realizando con 0

folds y 50 épocas, aún así se mantuvo la resolución y los pasos consecutivos listados anteriormente en el plan de implementación. Los pesos resultantes (*checkpoint_best.pth*) se evaluaron sobre un subconjunto de prueba de tres pacientes, calculando las métricas tal como se muestra en la Tabla 1.

Cuadro 1: Métricas de evaluación del modelo nnU-Net para segmentación de hígado y tumor

Paciente	Órgano	DSC	Sensibilidad	RVD (%)	NSD (2.0mm)
liver_94	Hígado	0.9622	0.9749	2.65	0.9048
liver_94	Tumor	0.6195	0.5402	-25.60	0.6515
liver_49	Hígado	0.9274	0.9325	1.10	0.7319
liver_49	Tumor	0.6930	0.7150	6.37	0.7105
liver_28	Hígado	0.9403	0.9670	5.67	0.7925
liver_28	Tumor	0.8315	0.7485	-19.95	0.6900

7.1. Métricas de Evaluación Cuantitativa

Para cuantificar el desempeño del modelo de segmentación frente a las etiquetas de referencia, se seleccionaron tres métricas complementarias que abordan el rendimiento desde perspectivas volumétricas, de detección y de contorno espacial: Sensibilidad, Diferencia Relativa de Volumen (RVD) y el Coeficiente de Dice de Superficie Normalizado (NSD).

La **Sensibilidad** mide la proporción de vóxeles que pertenecen a la clase real (hígado o tumor) y que fueron identificados correctamente por el algoritmo. En el contexto oncológico, esta métrica es de vital importancia, ya que un valor alto garantiza una tasa baja de falsos negativos, minimizando el riesgo de omitir tejido neoplásico. Matemáticamente se define como:

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

donde *TP* representa los verdaderos positivos y *FN* los falsos negativos.

La **Diferencia Relativa de Volumen (RVD)** evalúa la discrepancia en el tamaño total de la segmentación predicha frente a la anatomía real, independientemente de su solapamiento espacial. Un valor de RVD igual a cero indica una coincidencia volumétrica perfecta; valores positivos señalan

una sobre-segmentación, mientras que valores negativos evidencian una sub-segmentación (omisión de volumen). Se expresa porcentualmente mediante la ecuación:

$$RVD(\%) = \left(\frac{V_p - V_{gt}}{V_{gt}} \right) \times 100$$

donde V_p es el volumen total predicho por el modelo y V_{gt} es el volumen del *Ground Truth*.

Por último, el **Normalized Surface Dice (NSD)** es una métrica de distancia espacial que, a diferencia del Coeficiente de Dice tradicional (que evalúa el solapamiento global), el NSD cuantifica qué fracción de las superficies predichas y reales coinciden dentro de un margen de tolerancia predefinido (en este estudio, $\tau = 2,0$ mm). Esto es crucial en resecciones hepáticas, donde la precisión de los bordes define los márgenes quirúrgicos. Su formulación es:

$$NSD_\tau = \frac{|S_p \cap S_{gt}^\tau| + |S_{gt} \cap S_p^\tau|}{|S_p| + |S_{gt}|}$$

donde S_p y S_{gt} representan los vóxeles de la superficie de la predicción y de la verdad clínica, respectivamente, y S^τ la región de la superficie extendida por la tolerancia τ .

7.2. Análisis de Desempeño en Tejido Hepático

Los resultados listados en la Cuadro 1 indican que la red neuronal ha identificado de buena manera la morfología del parénquima hepático. Se observan valores del Coeficiente de Dice (DSC) consistentes y superiores a 0.92 en todos los casos, alcanzando un máximo de 0.9622. La sensibilidad supera el 0.93 de forma generalizada, lo que demuestra que la predicción se encuentra dentro de la etiqueta real. La Diferencia Relativa de Volumen (RVD) muestra valores positivos marginales (entre 1.10 % y 5.67 %), lo que indica una ligera sobre-segmentación y el Normalized Surface Dice (NSD) a 2.0 mm, que confirma que los bordes predichos poseen un pequeño margen de equivocación. Sin embargo al apreciar la imagen Figura 3, en el caso particular del paciente 94, la predicción no logra segmentar por completo el parénquima hepático.




Figura 3: (Predicción VS Ground-Truth) Heat-Map de incertidumbre en la predicción del paciente 94. En Naranja la segmentación de tumor y en Rojo el parénquima hepático

7.3. Análisis de Desempeño en Lesiones Tumores

Como es de esperar en el inicio del entrenamiento, la segmentación de la masa neoplásica presenta un desafío mayor debido a su heterogeneidad intrínseca, bajo contraste y bordes difusos. A pesar de esto, el modelo logró un DSC destacable de 0.8315 en el paciente *liver_28*.

Clínicamente, el hallazgo más relevante de esta prueba se observa en la Diferencia Relativa de Volumen (RVD) para los tumores. En dos de los tres pacientes evaluados (*liver_94* y *liver_28*), la RVD presenta valores fuertemente negativos (-25.60 % y -19.95 %, respectivamente), acompañados de una sensibilidad más baja (0.5402 y 0.7485). Esto evidencia un comportamiento de segmentación incompleta, es decir, el modelo es muy conservador y está omitiendo partes de la lesión (falsos negativos). Esto resalta la necesidad imperativa de continuar el entrenamiento de la red (hasta completar las épocas planificadas), para que así la función de costo penalice estas omisiones y mejore la capacidad de la IA para delimitar los tumores.

7.4. Explicabilidad del Modelo (XAI) y Análisis de Incertidumbre

Para abordar la naturaleza de **Caja Negra** inherente a las redes neuronales y fomentar la confianza clínica en la herramienta, se implementó un mecanismo de Inteligencia Artificial Explicable (XAI) basado en la cuantificación de la incertidumbre predictiva. Se extrajeron las distribuciones de probabilidad *Softmax* de la última capa de la arquitectura nnU-Net para calcular la Entropía de Shannon a nivel de vóxel.

La ecuación de entropía aplicada se define como:

$$H(x) = - \sum_{c \in C} P(c|x) \log_2 P(c|x)$$

donde $P(c|x)$ representa la probabilidad predicha por la red de que el vóxel x pertenezca a la clase c (fondo, tejido hepático o neoplasia).

En la Figura 3, el mapa de calor resultante (XAI) se superpone a la tomografía original. Las zonas de color negro y morado oscuro representan regiones de alta certeza diagnóstica (baja entropía), coincidiendo generalmente con el centro de las estructuras anatómicas. Por el contrario, los gradientes cálidos (naranja y amarillo) indican áreas de alta incertidumbre computacional. Esta representación visual justifica la sub-segmentación observada en las métricas de volumen (RVD).

7.5. Discusión

La visualización comparativa de los cortes generados tras 50 épocas de entrenamiento expone claramente los efectos del subajuste (*underfitting*) en la arquitectura convolucional, particularmente frente a presentaciones oncológicas complejas como las lesiones multi-focales apreciadas en el paciente

94 (Figura 3). Sin embargo, el subajuste no indica que la red no pueda mejorar en la predicción, ya que como se muestra en la Figura 4 la red neuronal evidencia una clara tendencia la mejoría, apreciable en la curva de la función de pérdida, tanto del entrenamiento como de la validación.

En la evaluación de la Etiqueta segmentada manualmente, se observa la presencia de múltiples nódulos neoplásicos de pequeño diámetro localizados en la profundidad del parénquima. Sin embargo, la predicción del modelo omite por completo algunas de estas lesiones y exhibe una segmentación incompleta del hígado. Además se aprecia claramente un falso positivo crítico, clasificando erróneamente un área en el margen hepático como tejido tumoral. Este comportamiento indica que, en etapas tempranas del descenso de gradiente, no es capaz de interpretar correctamente las características que diferencian al parénquima del tumor, y menos aún en tejidos tan homogéneos como el parénquima hepático. Hecho que destaca la necesidad de un aumento de épocas y validación por folds que estuvo ausente en este estudio

A pesar del bajo rendimiento predictivo, la aplicación del mapa de Entropía de Shannon, demuestra un valor clínico notable. La lesión "alucinada" por el modelo en el margen anterior aparece con un núcleo de alta seguridad, pero circunscrita por un halo de alta incertidumbre, por lo que, es inferible que en de haber seguido con el entrenamiento la función de pérdida hubiera penalizado fuertemente esta "aparente seguridad".

En un entorno de diagnóstico real, este mapa de calor actuaría como una advertencia de seguridad para el radiólogo, indicando que el hallazgo computacional carece de confianza y debe ser descartado o revisado exhaustivamente, mitigando así el riesgo al automatizar la detección.



Figura 4: Curva de la función de costo del modelo entrenado

8. Conclusiones

La implementación de la arquitectura nnU-Net en el presente trabajo demostró ser altamente efectiva para establecer un flujo de trabajo automatizado y estandarizado en la segmentación de tomografías computarizadas, gracias su ajuste automático de características que varían a través de las épocas. Si bien el entrenamiento a 50 épocas reveló un evidente

subajuste (*underfitting*) del modelo predictivo, esta limitación técnica permitió validar empíricamente la necesidad y eficacia de la Inteligencia Artificial Explicable (XAI). La integración de mapas de calor basados en la Entropía de Shannon demostró ser una herramienta de seguridad clínica de suma relevancia, logrando cuantificar y visibilizar de manera precisa la incertidumbre computacional frente a las “alucinaciones” del modelo. De este modo, se justifica el entrenamiento del algoritmo hasta su convergencia óptima recomendada, para así garantizar que la herramienta diagnóstica opere como un sistema robusto, interpretable y seguro para la planificación oncológica y quirúrgica.

8.1. Futuros Trabajos y Continuidad

Para compensar el alto coste computacional que requiere la completitud del entrenamiento de la red, existen variadas alternativas no probadas en este estudio que pudieron haber sido alta utilidad, y que pueden explorarse como continuación de este estudio o trabajos posteriores:

- **Ajuste de Parches de Entrada:** nnU-Net admite un entrenamiento basado en parches de imágenes de entrada, lo que reduce significativamente la dimensionalidad de la red, sin embargo, encontrar el valor óptimo es un desafío de por sí, debido a que parches demasiado pequeños pueden generar una pérdida de información.
- **Reducción del *Batch-size*:** Al igual que los parches de entrada, la elección del tamaño de mini-lote se puede tratar como un hiperparámetro de prueba y error, donde se recomienda iniciar con un batch size pequeño, para incrementar su valor mientras la potencia de cómputo lo permita.
- **Reducción de profundidad/complejidad de la red:** A pesar de que la red posee una autoconfiguración y elección de parámetros como la cantidad de neuronas y capas, esta elección se puede hacer de forma manual para experimentar resultados con redes de menor calibre.

- **Emplear acumulación de gradiente:** Es una técnica que permite simular un aumento artificial del tamaño de lote. Esto se logra dividiendo un lote grande en varios minilotes, sumando los gradientes individuales y actualizando los pesos al final, por lo que, es especialmente útil cuando se aplican tamaños pequeños de lotes.
- **Habilitar puntos de control recurrentes:** Por defecto la red genera puntos de control cada 100 épocas, sin embargo, este se puede disminuir para recurrir a los guardados del modelo para continuar en caso de interrupciones o falta de RAM.
- **Utilizar imágenes en menor resolución:** La red tiene la capacidad de realizar un re-muestreo para reducir las dimensiones de las imágenes, intentando perder la menor cantidad de información posible.
- **Reducir el *Data-Augmentation*:** Este paso intrínseco de la red es optimizable mediante la reducción de transformaciones por lote o restricción de su número.
- **Configuración 2.5D:** Existen algunos modelos que incorporan una metodología donde reconstruyen un volumen de imágenes a partir de “láminas consecutivas”, sin embargo, nnU-Net no incorpora esta funcionalidad de manera nativa, por lo que, nuevamente se presenta como un desafío de implementación.

9. Declaración de uso de IA

Para este trabajo se utilizó Inteligencia Artificial generativa con la finalidad de mejorar la redacción, además de haber funcionado como ayuda para la escritura de Scripts en Python, sin embargo, estos fueron utilizados luego de una exhaustiva revisión y edición por parte del investigador, asegurándose siempre, de no vulnerar información privada ni omitiendo pasos críticos que comprometan el desarrollo del estudio o la formación técnica del autor del estudio.

Referencias

1. Bilic P, Christ P, Li HB, Vorontsov E, Ben-Cohen A, Kaissis G, et al. The Liver Tumor Segmentation Benchmark (LiTS). *Medical Image Analysis*. 2023 2;84:102680.
2. Ervik M, Lam F, Laversanne M, Colombet M, Ferlay J, Miranda-Filho A, Bray F. Global Cancer Observatory: Cancer Today.; 2024. Lyon, France: International Agency for Research on Cancer;[10/05/2026]. Disponible en: <https://gco.iarc.who.int/today>.
3. Llovet JM, Kelley RK, Villanueva A, Singal AG, Pikarsky E, Roayaie S, et al. Hepatocellular carcinoma. *Nature Reviews Disease Primers*. 2021 1;7:6.
4. Rumgay H, Arnold M, Ferlay J, Lesi O, Cabañas CJ, Vignat J, et al. Global burden of primary liver cancer in 2020 and predictions to 2040. *Journal of Hepatology*. 2022 12;77:1598-606.
5. Asrani SK, Devarbhavi H, Eaton J, Kamath PS. Burden of liver diseases in the world. *Journal of Hepatology*. 2019 1;70:151-71.

6. Melendez-Torres J, Singal AG. Early detection of hepatocellular carcinoma: roadmap for improvement. *Expert Review of Anticancer Therapy*. 2022 6;22:621-32.
7. Hatamizadeh A, Nath V, Tang Y, Yang D, Roth HR, Xu D. In: *Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images*. Cham Springer; 2022. p. 272-84.
8. He K, Gan C, Li Z, Rekik I, Yin Z, Ji W, et al.. *Transformers in Medical Image Analysis: A Review*; 2022.
9. Isensee F, Jaeger PF, Kohl SAA, Petersen J, Maier-Hein KH. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*. 2021 2;18:203-11.
10. Maier-Hein L, Eisenmann M, Reinke A, Onogur S, Stankovic M, Scholz P, et al. Why rankings of biomedical image analysis competitions should be interpreted with care. *Nature Communications*. 2018 12;9:5217.
11. Ronneberger O, Fischer P, Brox T. In: *U-Net: Convolutional Networks for Biomedical Image Segmentation*. Springer, Cham; 2015. p. 234-41.
12. Patrício C, Neves JC, Teixeira LF. Explainable Deep Learning Methods in Medical Image Classification: A Survey. *ACM Computing Surveys*. 2024 4;56:1-41.